

Faster RCNN 模型在坯布疵点检测中的应用

晏 琳 景军锋 李鹏飞

(西安工程大学,陕西西安,710048)

摘要: 探讨 Faster RCNN 模型在坯布疵点检测中的应用效果。在原始 Faster RCNN 的基础上,采用提取特征效果更好的深度残差网络,先使用残差网络进行坯布图像特征提取,再通过区域生成网络及 Fast RCNN 检测网络对坯布的疵点目标进行分类与检测。试验对比了 Faster RCNN 分别与 VGG16、ResNet101 结合时的检测结果,并讨论了不同参数对结果的影响。试验结果表明:该方法可以有效解决坯布疵点检测问题,检测准确率能够达到 99.6%。认为:基于 Faster RCNN 目标检测与 ResNet101 卷积神经网络相结合的方法能够满足坯布生产过程中对于表面疵点进行准确检测的需求。

关键词: Faster RCNN; ResNet101; 卷积神经网络; 坯布疵点检测; IoU; 特征

中图分类号: TS101 文献标志码: A 文章编号: 1000-7415(2019)02-0024-04

Application of Faster RCNN Mold Used in Gray Fabric Defect Detection

YAN Lin JING Junfeng LI Pengfei

(Xi'an Polytechnic University, Shaanxi Xi'an, 710048)

Abstract The application effect of Faster RCNN mold used in gray fabric defect detection was discussed. Based on original Faster RCNN, deep residual network with better feature extraction effect was adopted. Residual network was firstly used for the feature extraction of grey fabric. Then, network was generated by district and Fast RCNN detection network was used for the classification and detection of targeted defects in gray fabrics. The detection effect was compared when Faster RCNN was combined with VGG16 and ResNet101 respectively. The influence of different parameters on the results were discussed. The test results showed that the method could efficiently solve the defect detection problem of gray fabrics. The detection accuracy could be reached 99.6%. It is considered that the method by combining Faster RCNN target detection and ResNet 101 convolution neural network can meet the requirement of gray fabric production process on surface defect detection.

Key Words Faster RCNN, ResNet101, Convolution Neural Network, Gray Fabric Defect Detection, IoU, Feature Extraction

1 背景

坯布疵点的产生有多种原因,如织机性能不良、人为操作不当或布匹在运输中被意外污染等^[1]。目前,坯布疵点的检测仍基本依靠人工完成,但人工检测方法存在效率低、误检率高、漏检率高等缺点。传统的织物检测算法仅针对特定的疵点检测效果较好,但检测疵点的种类有限,无法

满足织物疵点种类较多的情况^[2]。

2012 年,深度卷积神经网络首次出现,由 Hinton 提出的 AlexNet^[3] 取得当年 ImageNet^[4] 图像分类竞赛冠军。随后,深度神经网络得到长足发展,提出如 GooleNet^[5]、VGG^[6]、深度残差网络(ResNet)^[7-8] 等经典神经网络。其中 VGG 采用 3×3 的滤波器,增加了网络结构的深度,促进了卷积神经网络结构研究进程;ResNet 利用残差学习,解决了传统神经网络结构梯度消失的问题,真正意义上实现了深度神经网络的训练。随着深度学习算法的不断发展,近年来在目标检测领域,提出了基于区域建议的目标检测与识别算法。2014 年发表的 RCNN 算法^[9],首次采用目标候

基金项目:陕西省重点研发计划(2017GY-003)

作者简介:晏琳(1994—),女,在读硕士研究生;景军锋,通信作者,教授,413066459@qq.com

收稿日期:2018-07-27

选区域和深度学习相结合的方法,将检测任务转化为分类任务。此后,陆续提出了优化后的 Fast RCNN 算法和 Faster RCNN 算法^[10],在该领域进行了广泛的应用。本文对 Faster RCNN 算法在坯布疵点检测中的应用进行了研究。

2 基于区域选择的目标检测算法

2.1 经典算法

基于区域选择的目标检测算法是现阶段较成熟的目标检测与识别框架,它将检测过程简化为分类任务,并利用深度学习方法提升检测精度,其中具有代表性的算法为 RCNN、Fast RCNN 以及 Faster RCNN。RCNN 利用 Selective Search 提取目标候选区域,在候选区域中通过 CNN 网络提取特征,并训练 SVM 分类器,对特征分类^[11]。其改进模型 Fast RCNN 提出了 ROI 池化 (Region of Interest Pooling) 层并采用 Softmax 预测区域类别,提高了模型的检测精度及效率。为了进一步提高检测速率,在 Fast RCNN 基础上提出了 Faster RCNN 算法。

2.2 Faster RCNN 原理

Faster RCNN 算法包含两个卷积神经网络,其结构如图 1 所示。Faster RCNN 由区域生成网络 (Region Proposal Networks, RPN) 和 Fast RCNN 两部分构成,RPN 用于生成目标可能存在的候选区域;Fast RCNN 实现对候选区域的分类,并且进行边界回归。这两部分共享一个提取特征的卷积神经网络,使得目标候选区域的检测时间几乎为零,大幅提高了目标检测的速度。




图 1 Faster RCNN 结构示意图

RPN 是一个全卷积神经网络 (Fully Convolutional Network, FCN)^[12],其以原始图像所提取的任意大小特征图作为输入,输出目标候选框的集

合。RPN 采用一个 $n \times n$ 的滑动窗口在共享卷积网络的输出特征图上进行滑窗选择,针对每个窗口,同时预测 k 个目标候选区,即有 k 个相对应的被称为锚 (Anchor) 的初始区域。对于一张大小为 $w \times h$ 的卷积特征图,则可得到 $w \times h \times k$ 个锚。每个窗口被映射为一个低维向量,该特征向量输出给边框分类网络和边框回归网络^[13]。使用分类网络得到锚属于前景或背景的概率,并使用边框回归网络修正锚的边界框。RPN 的训练过程采用端到端 (End-to-end) 的方式,其损失函数通过平衡因子将分类损失和回归损失联合,利用该损失函数训练好的 RPN 能够得到目标候选区域,这些候选区域再在 Fast RCNN 部分进一步检测。

Fast RCNN 检测网络。目标候选区域的特征经过 Fast RCNN 中的 ROI 池化层后,输出固定长度的特征向量。这些特征向量通过全连接层分别输入 Softmax 分类器和边框回归网络中以预测区域类别并修正边框。为了精调整个网络,Faster RCNN 采用文献^[11]中提出的交替训练法训练网络。RPN 与 Fast RCNN 共享相同的特征提取层,构成统一的网络。

3 试验分析

试验使用的坯布疵点数据来自于现场采集,整个数据集共包含 2 000 张图片。图片尺寸均为 $256 \text{ pixel} \times 256 \text{ pixel}$,选择其中的 1 320 张图片作为训练集及验证集,剩余的 680 张图片作为测试集。在人工标注疵点的边框后,将数据集转化为 VOC2007 的格式进行训练。

试验硬件平台操作系统 Ubuntu 16.04 LTS 64 位,CPU Intel (R) Core (TM) i5-8400 2.80GHz,GPU NVIDIA GeForce GTX 1080 Ti,内存 16 G,硬盘 1 TB,整个试验均基于深度学习框架 TensorFlow 进行,编程语言为 Python,通过多次试验优选得到结果。

为评估 Faster RCNN 在坯布疵点检测中的有效性,采用平均准确率均值 (mean Average Precision, mAP) 来作为衡量模型性能的指标。 mAP 是指所有类别目标的平均准确率 (Average Precision, AP) 的均值,它可以作为目标检测的实际度量标准。

3.1 不同特征提取网络下的检测效果

由于 ImageNet 数据集的训练图像种类众

多, 用其训练的模型具有较好的特征表达能力及泛化能力, 所以在试验中, 将 ImageNet 分类预训练后得到的 VGG16、ResNet101 模型分别用于进行 Faster RCNN 共享卷积层的初始化以得到初始参数及权重。将坯布疵点数据集放入整个模型中进行训练。在不同的特征提取网络下, 随着迭代次数的变化, 其 mAP 值见表 1。

表 1 不同特征提取网络下的检测效果

迭代次数/次	$mAP/\%$	
	Faster RCNN+VGG16	Faster RCNN+ResNet101
10 000	91.72	93.99
30 000	94.91	96.99
50 000	97.15	99.49
70 000	97.26	99.44

由表 1 得出, ResNet101 在测试集中, 相较于原始的 VGG16 网络, mAP 值提高了 2.3% 左右, 从而证明 ResNet101 在坯布疵点检测中的性能优于 VGG16。这是由于 ResNet101 引入了残差学习模块, 残差学习将神经网络的输出由 $H(x)$ 变为 $F(x) = H(x) + x$, 减弱了因为卷积层数过多而造成的梯度消失现象, 提高了检测的准确率。因此在坯布疵点检测的过程中, 选择采用 Faster RCNN 与 ResNet101 相结合的方法。

3.2 不同参数设置下的检测效果

试验过程中的一些参数, 例如非极大值抑制 (Non-maximum Suppression, nms) 前后区域保留个数、批处理尺寸、最大交并比 (Intersection over Union, IoU), 这些参数对试验结果均有影响, 因此, 进行了多次对比试验以确定最优参数配置。

nms 在 Faster RCNN+ResNet101 模型中的作用是去除具有较大重叠区域的锚。令迭代次数为 50 000 次, 测试不同的 nms 前后候选区域个数对 mAP 值的影响, 结果见表 2。由表 2 得出, 随着数量的减少, 模型保留的锚数也随之减少, 导致

检测结果的 mAP 值下降。因此, 选择相对较高的 nms 候选区域个数能够得到较好的检测结果。

表 2 不同 nms 个数对 mAP 影响


迭代次数/次	nms 前 候选区域/个	nms 后 候选区域/个	$mAP/\%$
50 000	12 000	2 000	99.49
50 000	9 000	1 700	99.31
50 000	6 000	1 400	98.87
50 000	3 000	1 100	97.10

在实践中, 批尺寸的个数决定了单次训练样本的数目, 其数值的选取会对训练过程中的梯度下降产生影响。试验分别测试了采用不同批尺寸时, 模型的 mAP 值, 结果见表 3。通过分析表 3 得出, 在合理的范围内, 批尺寸越大, 相应的 mAP 值会提高, 同时每 20 次迭代所需要的训练时间也会增加。考虑到小的批尺寸需要小的学习速率以保持稳定性, 所以, 在此选择较大的批尺寸来进行模型训练。

表 3 不同批尺寸对 mAP 影响

迭代次数/次	区域提议阶段 批尺寸/个	检测阶段 批尺寸/个	$mAP/\%$	训练时间/ms
50 000	256	256	99.58	366
50 000	128	64	98.47	227
50 000	64	32	97.12	202
50 000	32	16	94.71	185

在 RPN 部分的训练过程中, 得到的锚根据 IoU 被分为两类, 在初始模型中, 当 IoU 值大于等于 0.7 时被分为前景; 当 IoU 值小于 0.3 时被分为背景。 IoU 取值对 loss 曲线的影响如图 2 所示。由图 2 得出, 调整 IoU 的值可以改变 loss 曲线的收敛效果, 其中当 IoU 值分别取 0.9 和 0.1 时效果最好。这是由于白坯布的背景简单, 适当地增加前景的 IoU 值并降低背景 IoU 值可以选择留下较优的锚。

图 2 IoU 取值对 loss 曲线的影响

3.3 试验结果

试验中,采用调优的参数配置后,Faster RCNN+ResNet101 模型得到的部分检测结果如图 3 所示。在图 3 中,包围框区域代表坯布疵点存在的位置,包围框的左上方显示了该模型对于方框区域目标的分类类别及其类别概率值。图 3(a)中污渍的概率值为 1.000,图 3(b)中长断纬的概率值为 0.988,短断纬的概率值为 0.987;图 3(c)中线条的概率值为 1.000,图 3(d)中褶皱的概率值为 0.993。




图 3 Faster RCNN+ResNet101 模型的部分检测结果图

4 结论

研究采用 Faster RCNN 分别与不同特征提取网络相结合的方法进行坯布疵点检测,可检测多种不同类型的坯布疵点。通过试验验证,ResNet101 相较于 VGG16 能够取得更好的检测效果。试验表明,Faster RCNN 与 ResNet101 相结合的方法可以应用于检测坯布的疵点,该方法能够自动提取疵点特征,经过多次合理的模型参数优化后,检测准确率高达 99.6%。但是,由于 ResNet101 的层数较深,导致对一张图像的检测时间稳定在 130 ms 左右,其实时性还有待提高。在未来的研究中,会通过优化特征提取层的卷积神经网络以进一步提升模型的实时性,在保证检测效果的前提下,更快速地进行检测。

参考文献:

[1] 陈俊杰,谢春萍.自动验布系统[J].纺织科技进展,

2004(5):56-57.

- [2] 杨曼.基于改进迭代匹配滤波的织物疵点检测[J].西安工程大学学报,2017,31(3):383-389.
- [3] KRIZHEVSKY A,SUTSKEVER I,HINTON G E. Imagenet Classification with Deep Convolutional Neural Networks[C]//Advances in Neural Information Processing Systems,2012:1097-1105.
- [4] DENG J,DONG W,SOCHER R,et al. Imagenet: A Large-scale Hierarchical Image Database[C]//Computer Vision and Pattern Recognition, 2009: 248-255.
- [5] SZEGEDY C,LIU W,JIA Y,et al. Going Deeper with Convolutions[C]//Computer Vision and Pattern Recognition,2015.
- [6] SIMONYAN K,ZISSERMAN A. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. Computer Science,2014.
- [7] HE K,ZHANG X,REN S,et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2016,770-778.
- [8] HE K,ZHANG X,REN S,et al. Identity Mappings in Deep Residual Networks[C]//European Conference on Computer Vision. Springer, Cham, 2016: 630-645.
- [9] GIRSHICK R,DONAHUE J,DARRELL T,et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2014:580-587.
- [10] REN S,HE K,GIRSHICK R,et al. Faster R-CNN: Towards Real-time Object Detection with Region Proposal Networks[C]//Advances in Neural Information Processing Systems,2015:91-99.
- [11] UIJLINGS J R R,SANDE K E A V D,GEVERS T,et al. Selective Search for Object Recognition[J]. International Journal of Computer Vision, 2013, 104 (2):154-171.
- [12] LONG J,SHELHAMER E,DARRELL T. Fully Convolutional Networks for Semantic Segmentation [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 3431-3440.
- [13] ELZENSZWALB P F,GIRSHICK R B,MCALLESTER D,et al. Object Detection with Discriminatively Trained Part-based Models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence,2010,32(9):1627-1645.